

FET445 Veri Madenciliği

Araba Fiyat Tahmini

Grup : Motor Çetesi

Tarih:25.12.2025

Problem Tanımı

Bu projede, ikinci el araç piyasasında yer alan fiyatların gerçekçi olup olmadığını analiz etmek ve kullanıcılara veriye dayalı bir fiyat tahmini sunmak amaçlanmıştır.

Craigslist.org üzerinden elde edilen ikinci el araç verileri kullanılarak, araçların sayısal ve kategorik özelliklerine dayalı bir makine öğrenmesi modeli geliştirilmiştir.

Problem, araç özelliklerinden yola çıkarak satış fiyatını tahmin etmeyi hedefleyen bir regresyon problemi olarak ele alınmıştır.

Modelin başarımı MAE, RMSE ve R^2 metrikleri ile değerlendirilmiş; düşük tahmin hatası ve yüksek açıklayıcılık elde edilmesi hedeflenmiştir.

Veri Seti

Bu projede, ABD genelinde yayınlanan ikinci el araç ilanlarını içeren Craigslist Cars & Trucks Dataset kullanılmıştır. Veri seti, Craigslist.org üzerinden web scraping yöntemiyle toplanmış gerçek araç ilanlarından oluşmaktadır.

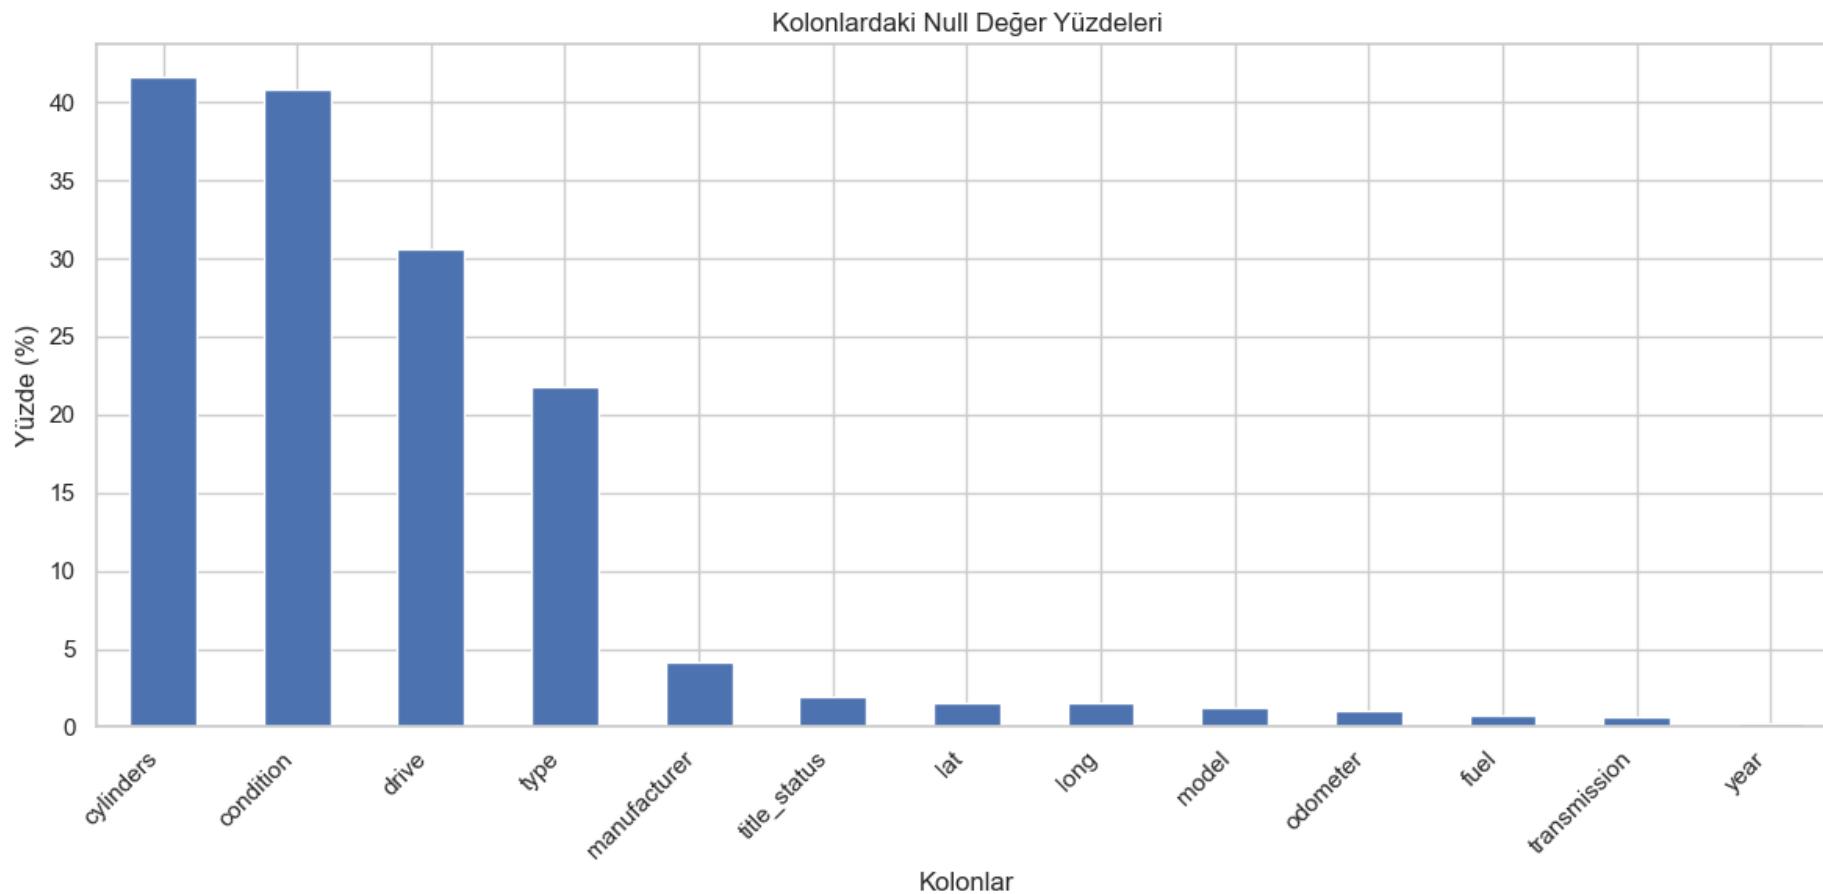
Amaç, araçlara ait sayısal, kategorik ve ordinal özelliklerini kullanarak satış fiyatını tahmin etmektir. Farklı araç tipleri, üreticiler ve kullanım durumlarını kapsaması sayesinde veri seti, gerçekçi ve geniş bir piyasa temsili sunmaktadır.

Veri Seti Boyutu



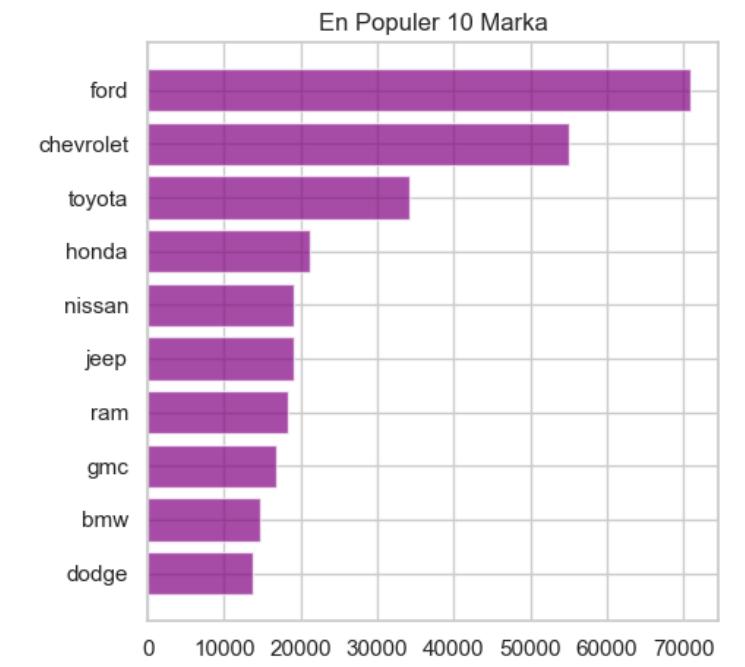


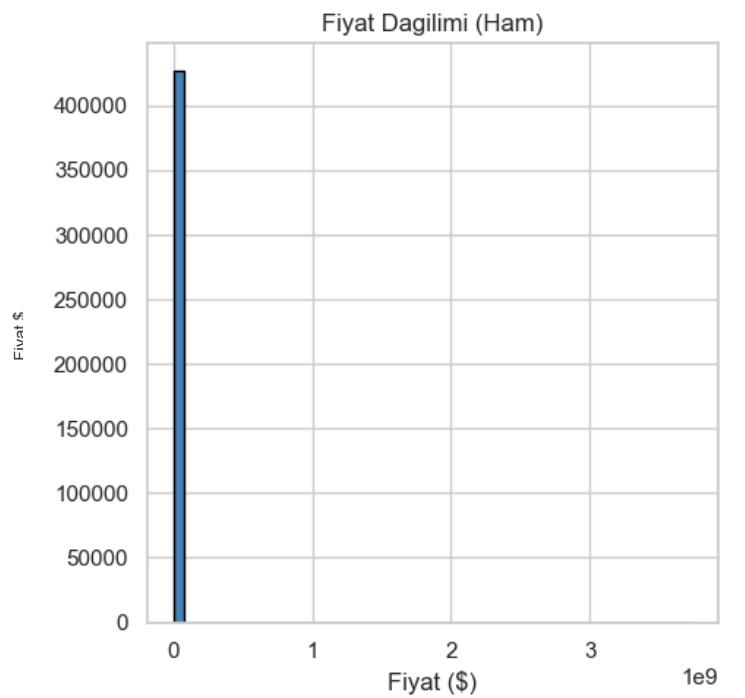
- Toplam satır sayısı: 426.880
- Toplam sütun sayısı: 26
- Dosya boyutu: ~1.45 GB (CSV)

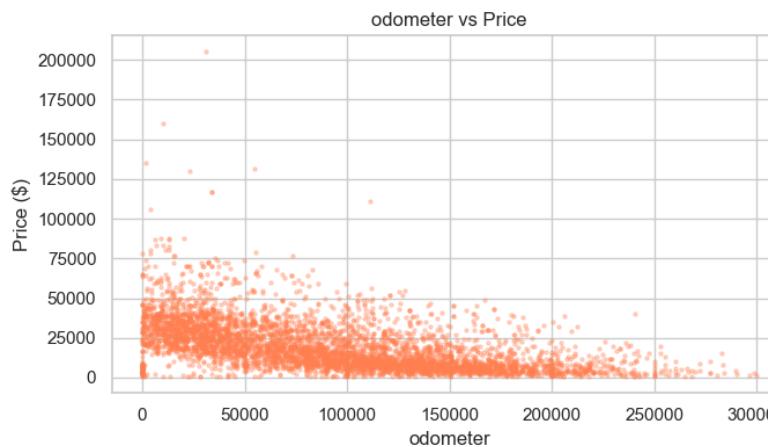
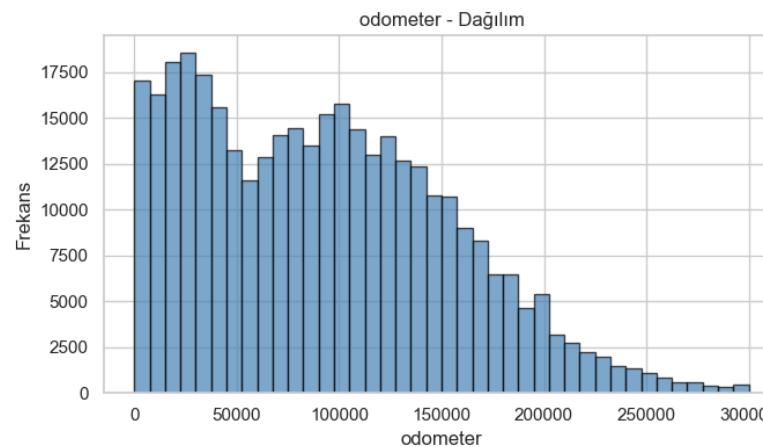


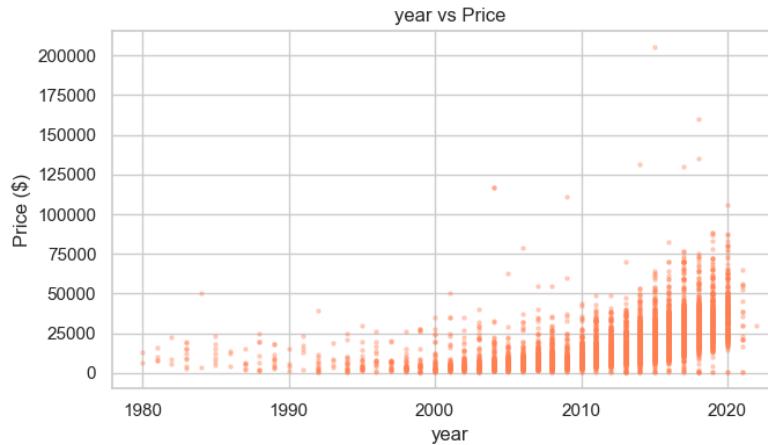
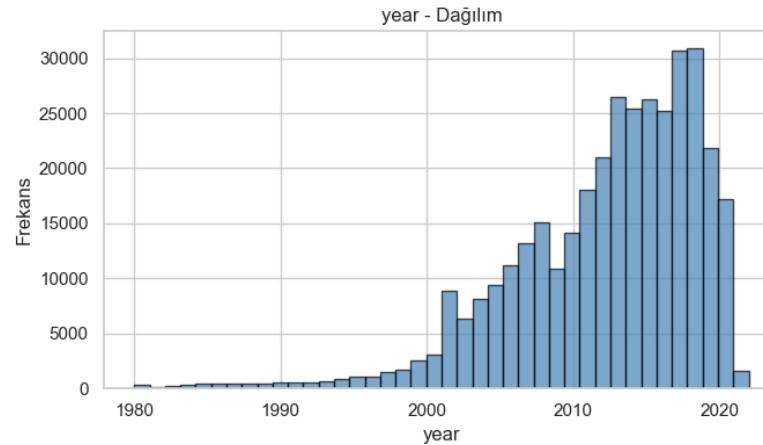
Veri Seti Özellik Tipleri

- Sayısal özellikler:
price (hedef değişken), year, odometer, cylinders, latitude, longitude
- Kategorik özellikler:
manufacturer, fuel, transmission, drive, type, paint_color, title_status, state, region
- Ordinal özellikler:
condition




EDA öncesi kolonlardaki null değer yüzde grafiği







manufacturer - Değer Dağılımı (Top 15)




condition - Değer Dağılımı (Top 15)



fuel - Değer Dağılımı (Top 15)



title_status - Değer Dağılımı (Top 15)



Her bir ekip üyesi farklı feature engineering modelleri + sabit bir baseline model kullanarak farklı feature engineering tekniklerinin direkt olarak R2 , RMSE , MAE metriklerine etkisini test etmiştir. Kullanılan bazı feature engineering teknikleri:

```
def categorize_engine(cylinders):
    if cylinders <= 4:
        return 'small_engine'
    elif cylinders <= 6:
        return 'medium_engine'
    else:
        return 'large_engine'

df['engine_category'] = df['cylinders'].apply(categorize_engine)
```

```
def categorize_age(age):
    if age <= 2:
        return 'brand_new'
    elif age <= 5:
        return 'new'
    elif age <= 10:
        return 'mid_age'
    elif age <= 15:
        return 'old'
    else:
        return 'very_old'

df['age_category'] = df['car_age'].apply(categorize_age)
```

```
# 1) Arac yasi
df['car_age'] = 2025 - df['year']
print('car_age eklendi')

# 2) Yillik km
df['mil_per_year'] = df['odometer'] / df['car_age'].replace(0, 1)
print('mil_per_year eklendi')

# 3) Condition düzeltme (km bazlı)
def correct_condition(row):
    odometer = row['odometer']
    if odometer <= 10000: return 'new'
    elif odometer <= 50000: return 'like new'
    elif odometer <= 100000: return 'excellent'
    elif odometer <= 150000: return 'good'
    else: return 'fair'

df['condition'] = df.apply(correct_condition, axis=1)
print('condition km bazlı düzeltildi')
```

```
Toplam canonical model sayısı: 665  
Toplam model varyant sayısı: 1050
```

```
=====  
MODEL NORMALİZASYON İŞLEMİ  
=====
```

```
Ham model NaN sayısı: 4,452  
Normalize edilmiş model sayısı: 364,044
```

```
Sözlükte olmayan model sayısı: 202,516  
Bu modeller 'unknown' olarak işaretlenecek (silinmeyecek)
```

```
Final dataframe boyutu: 368,498 satır (veri kaybı yok!)\nModel kolonu hazır: 364,044 normalize edilmiş model\n  - Bilinen modeller: 165,982\n  - Unknown modeller: 202,516
```

```
=====  
MODEL NORMALİZASYON TAMAMLANDI  
=====
```

```
=====  
UNKNOWN MODEL DEĞERLERİNİ DOLDURMA (Manufacturer'a göre)  
=====
```

```
Doldurulacak unknown model sayısı: 202,516
```

```
Manufacturer bazında en popüler modeller bulundu: 40 manufacturer
```

```
Doldurma sonuçları:
```

- Doldurulan model sayısı: 202,100
- Kalan unknown model sayısı: 416
- Doldurma oranı: 99.8%
- Kalan 416 unknown değer 'other' olarak işaretlendi

```
=====  
UNKNOWN MODEL DOLDURMA TAMAMLANDI  
=====
```

```
==== TYPE DOLDURMA (MODEL BİLGİSİ İLE) ===
```

```
Başlangıç type null: 86295
```


- 1) Model isminden type çıkarılıyor...
Sonrası null: 49988
- 2) Manufacturer bazlı mode...
Sonrası null: 0
- 3) Kalan null'lar 'unknown' yapılıyor...
Final null: 0

```
Type doldurma tamamlandı!
```

```
Type dağılımı:
```


type	count
sedan	117634
SUV	90340
pickup	74027
truck	33492
other	21246
coupe	20649
hatchback	17236
van	10720
wagon	10532
convertible	7152
mini-van	4682
offroad	570
bus	314

Name: count, dtype: int64



Train Test Split Oranı : %80 Train %20 Test

Kullanılan Performans metrikleri : R2 , MAE , RMSE



Yapılan deneyler sonucunda, GPU desteğiyle hızlı eğitilebilmesi ve test verisi üzerinde en iyi performans metriklerini sağlaması nedeniyle XGBoost en başarılı model olarak seçilmiştir. Hiperparametre optimizasyonunda, GridSearchCV'ye kıyasla çok daha hızlı çalışması ve benzer verimlilikte sonuçlar üretmesi nedeniyle ağırlıklı olarak

RandomizedSearchCV kullanılmıştır. Optimizasyon sürecinde ağaç sayısı, maksimum derinlik, öğrenme oranı ve örneklemeye oranı gibi temel hiperparametreler ayarlanmıştır. Model; araç yılı, kilometre, motor ve yakıt özellikleri, şanzıman, araç tipi, çekiş türü, üretici bilgisi ve coğrafi konum gibi sayısal ve kategorik özellikler kullanılarak eğitilmiştir.

Ekip Üyesi	Kullanılan Model	Hyperparameter Tuning Yöntemi	En Optimum Parametreler	Kullanılan Performans Metrikleri
Buğra	Random Forest Regressor	RandomizedSearchCV (n_iter=12, cv=3)	n_estimators=400, max_depth=20, min_samples_split=5, min_samples_leaf=2, max_features="sqrt"	RMSE, MAE, R ²
Buğra	PyTorch Neural Network (MLP)	Manual Tuning	learning_rate=0.001, batch_size=32, epochs=50	RMSE, Loss, R ²
Emirhan	XGBoost Regressor	RandomizedSearchCV (n_iter=30, cv=3)	n_estimators=1000, max_depth=8, learning_rate=0.05, subsample=0.8	RMSE, MAE, R ²
Emirhan	LightGBM Regressor	RandomizedSearchCV (n_iter=30, cv=3)	n_estimators=500, max_depth=10, learning_rate=0.1, num_leaves=31	RMSE, MAE, R ²
Utku	Bagging Ensemble (KNN)	RandomizedSearchCV (n_iter=10, cv=3)	n_estimators=200, max_samples=1.0, learning_rate=0.1	RMSE, MAE, R ²
Utku	CatBoost	Randomized Search	n_estimators=800, max_depth=8, learning_rate=0.05, loss_function="RMSE"	RMSE, MAE, R ²
Alper	HistGradientBoostingRegressor	Manual Tuning (iterative parameter refinement)	max_depth=15, learning_rate=0.03, max_iter=800	RMSE, MAE, R ²
Alper	Stacking Regressor	Grid Search (meta-model & base model selection)	base_models=[RF, LGBM, XGB], final_estimator=LinearRegression	RMSE, MAE, R ²

R² Score (↑)	RMSE (\$) (↓)	MAE (\$) (↓)
XGBoost : 0.8869	Random Forest : 3,950.88	Bagging KNN : 2,033.50
Random Forest : 0.8831	XGBoost : 3,992.31	Random Forest : 2,220.24
LightGBM : 0.8698	LightGBM : 4,389.76	XGBoost : 2,393.11
Bagging KNN : 0.8380	Bagging KNN : 5,153.38	Stacking Regressor : 2,426.28
Stacking Regressor : 0.8202	Stacking Regressor : 5,375.21	LightGBM : 2,745.36
CatBoost : 0.8178	CatBoost : 5,473.67	CatBoost : 2,660.70
HistGradientBoosting : 0.7299	HistGradientBoosting : 7,602.93	HistGradientBoosting : 4,152.12
PyTorch ResNet MLP : 0.7152	PyTorch ResNet MLP : 7,956.78	PyTorch ResNet MLP : 4,423.55