FET445 Veri Madenciliği

Araba Fiyat Tahmini

Grup : Motor Çetesi

Youtube Linki:

https://youtu.be/GEEwlQNA0kQ?si=O_5HmG1Grohzuxr2

Tarih:25.12.2025

Araba Fiyat Tahmini

Bu projede, ikinci el araç piyasasında karşılaşılan fiyatların gerçek değerleri yansıtıp yansıtmadığını analiz etmek ve kullanıcıya veri temelli bir fiyat tahmini sunmak amaçlanmaktadır. Craigslist.org sitesinden elde edilen ikinci el araç verileri kullanılarak, araçların sayısal ve kategorik özelliklerine dayalı bir fiyat tahmin modeli geliştirilmiştir. Problem, araç özelliklerinden yola çıkarak satış fiyatını öngörmeyi hedefleyen bir regresyon problemi olarak ele alınmıştır. Model performansı MAE, RMSE ve R^2 metrikleri ile değerlendirilmiş; tahmin hatalarının kontrol altında tutulması ve yüksek açıklayıcılık sağlanması hedeflenmiştir.

Veri Seti Açıklaması

Bu projede, ABD'de yayınlanan ikinci el araç ilanlarını içeren Craigslist Cars C Trucks Dataset kullanılmıştır. Veri seti, Craigslist.org sitesi üzerinden web scraping yöntemiyle toplanmış araç ilanlarından oluşmaktadır. Amaç, araçların sayısal ve kategorik özelliklerini kullanarak satış fiyatlarını tahmin etmektir. Veri seti, farklı araç tipleri, üreticiler ve kullanım durumlarını kapsayarak geniş ve gerçekçi bir piyasa temsili sunmaktadır

Veri Seti Linki

Veri setine Kaggle üzerinden erişilmiştir: https://www.kaggle.com/datasets/austinreese/craigslist-carstrucks-data

Veri Seti Boyutu

- Toplam satır sayısı: 426.880
- Toplam sütun sayısı: 26
- Dosya boyutu: ~1.45 GB (CSV)

Veri Seti Özellik Tipleri

- Sayısal özellikler:
  price (hedef değişken), year, odometer, cylinders, latitude, longitude
- Kategorik özellikler:
  manufacturer, fuel, transmission, drive, type, paint_color, title_status, state, region
- Ordinal özellikler:
  condition (durum seviyesi)

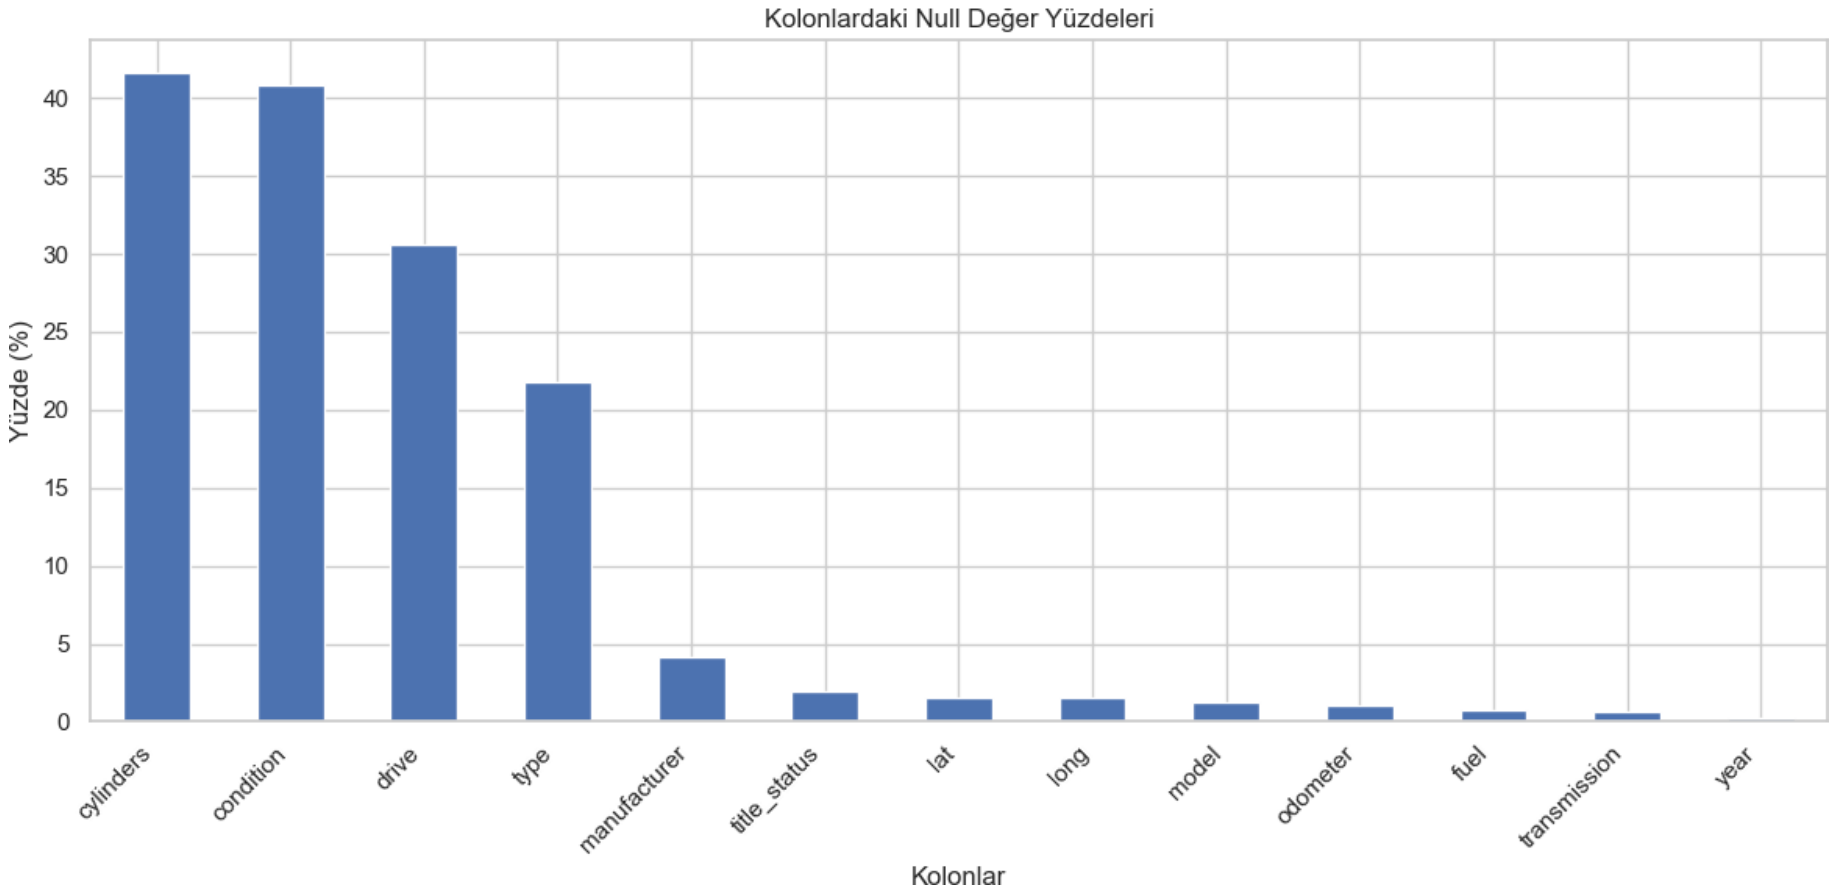

EDA öncesi kolonlardaki null değer yüzde grafiği

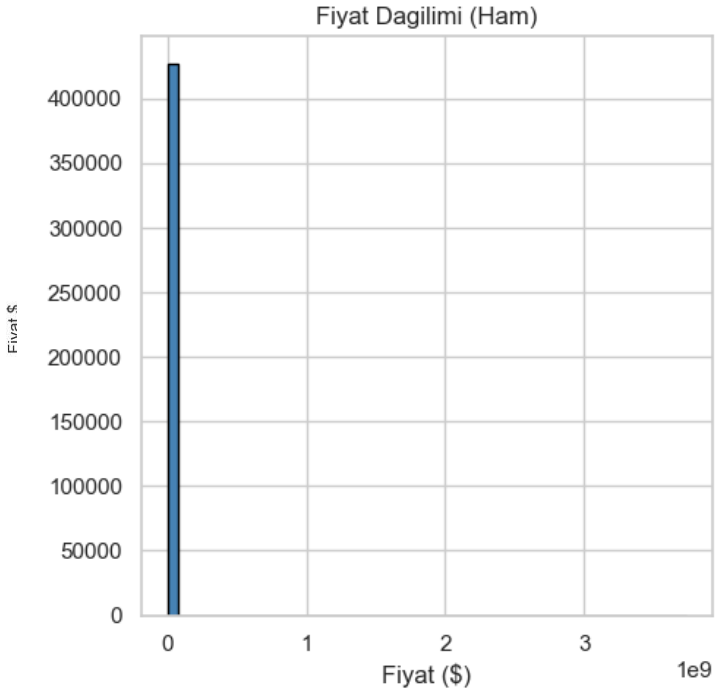
Fiyat Dagilimi (Ham)
Fiyat $
Fiyat ($)
1e9

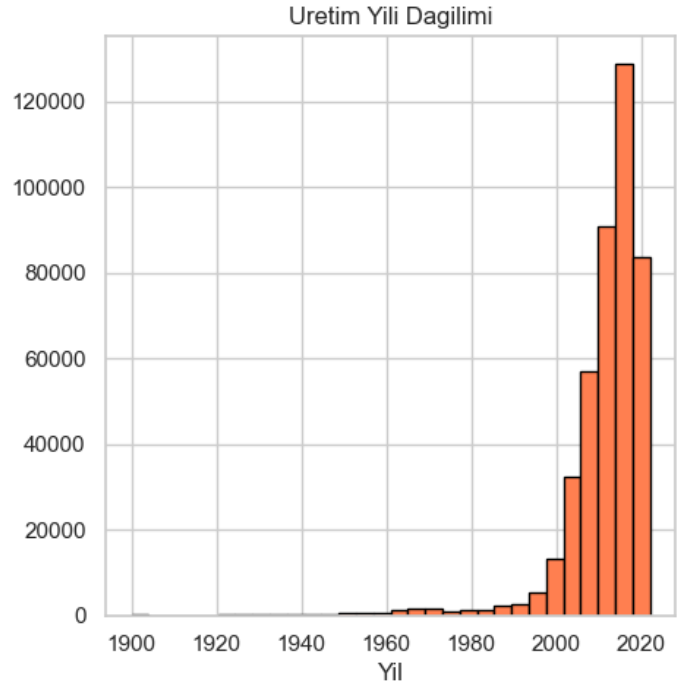
Uretim Yili Dagilimi
Yil

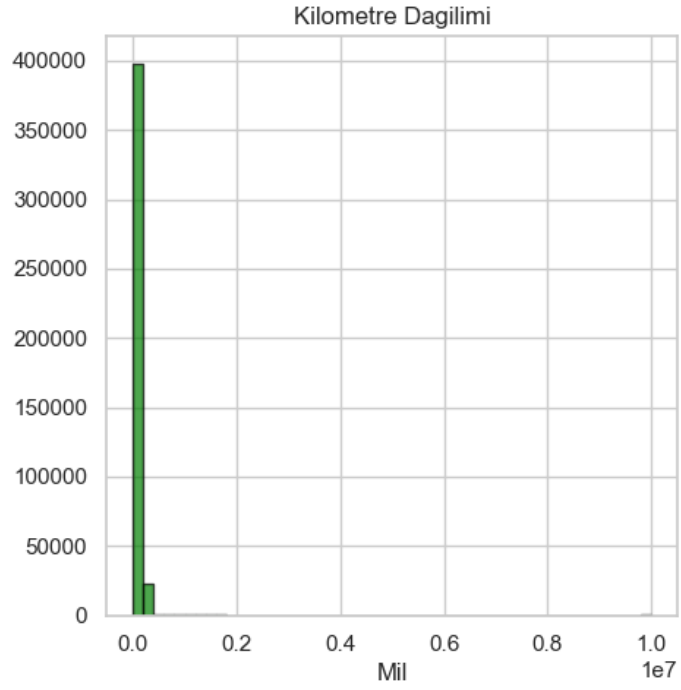
Kilometre Dagilimi
Mil
1e7

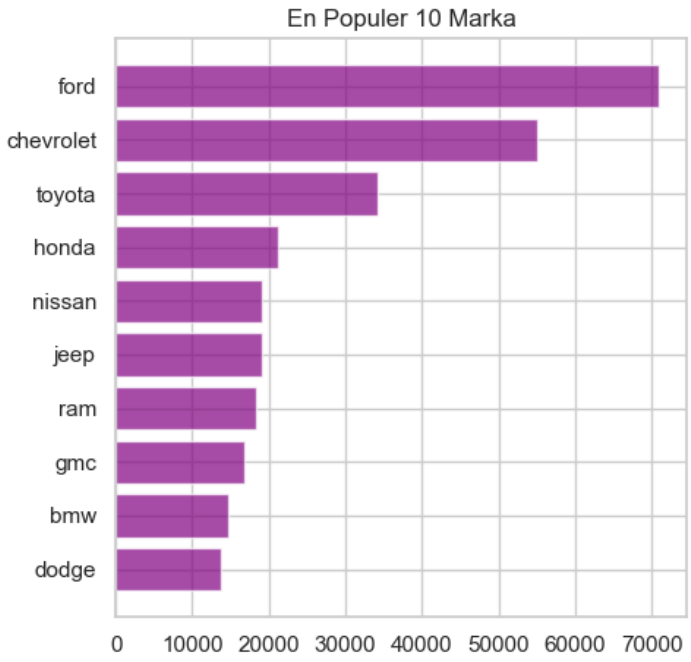
En Populer 10 Marka
ford
chevrolet
toyota
honda
nissan
jeep
ram
gmc
bmw
dodge

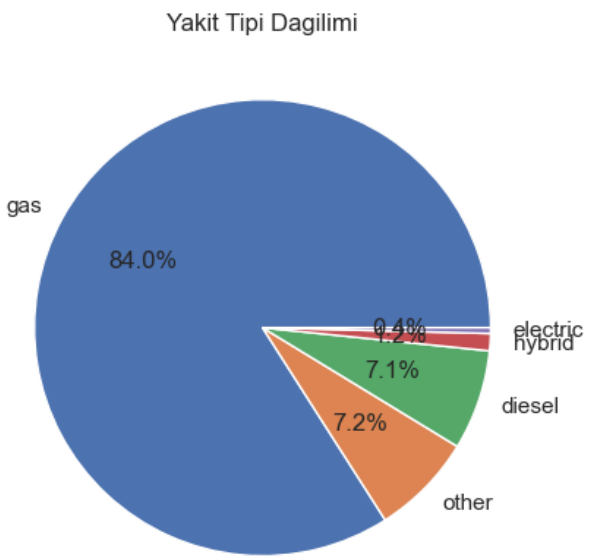
Yakit Tipi Dagilimi
gas
84.0%
electric
hybrid
diesel
7.1%
other
7.2%

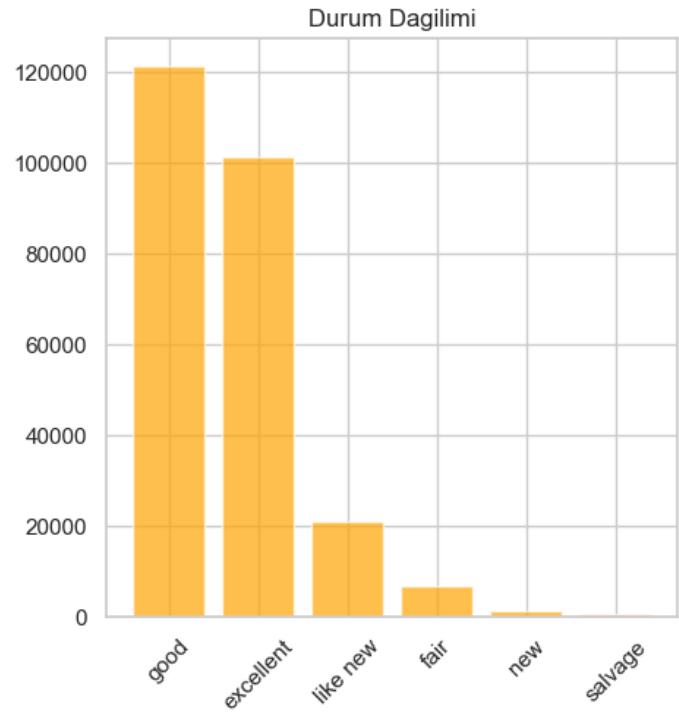
Durum Dagilimi
good
excellent
like new
fair
new
salvage

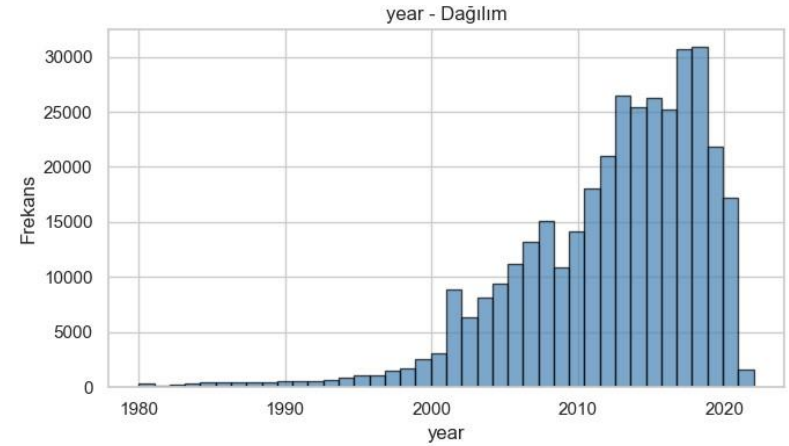
year - Dağılım
Frekans
year
0
5000
10000
15000
20000
25000
30000
1980
1990
2000
2010
2020

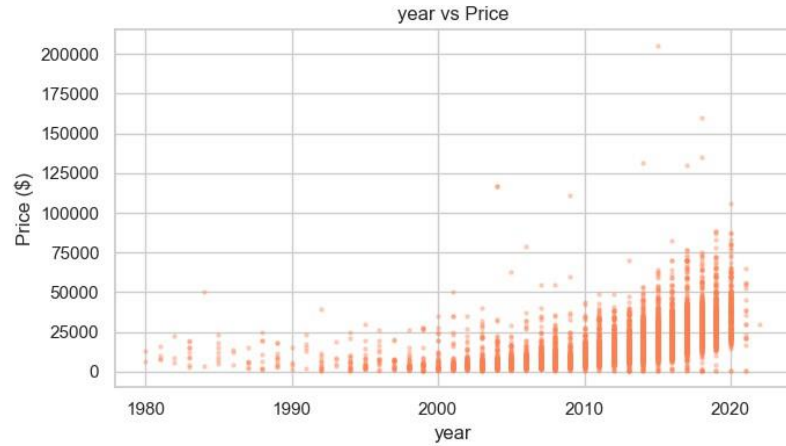
year vs Price
Price ($)
year
0
25000
50000
75000
100000
125000
150000
175000
200000
1980
1990
2000
2010
2020

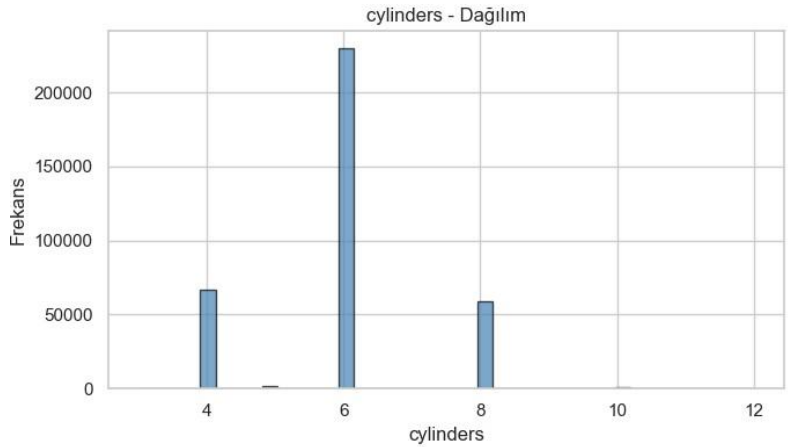
cylinders - Dağılım
Frekans
cylinders
0
50000
100000
150000
200000
4
6
8
10
12

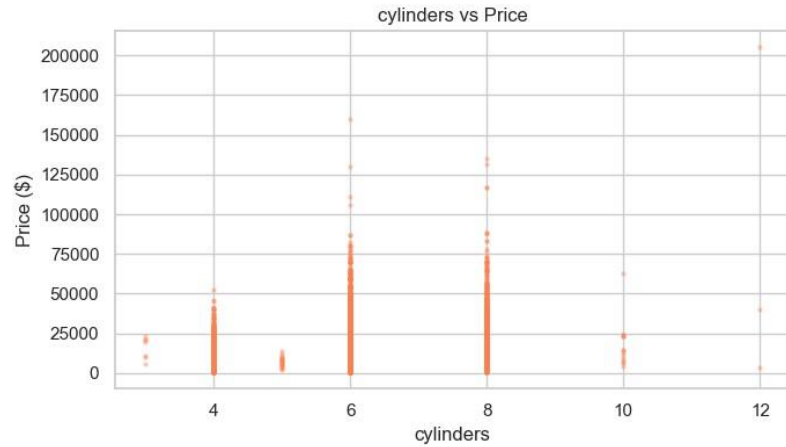
cylinders vs Price
Price ($)
cylinders
0
25000
50000
75000
100000
125000
150000
175000
200000
4
6
8
10
12

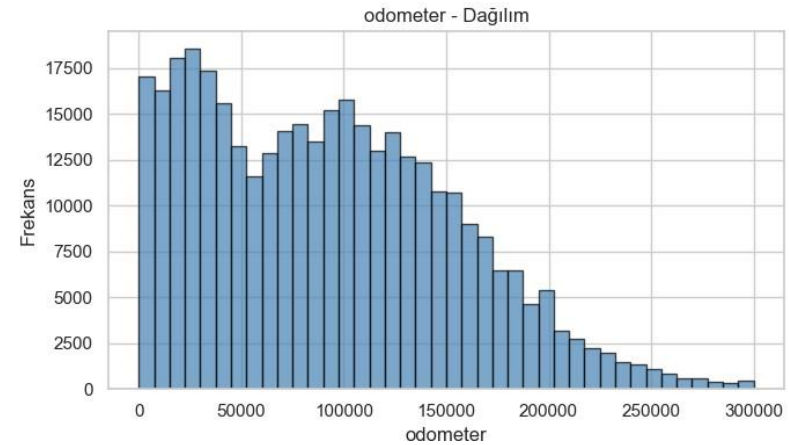
odometer - Dağılım
Frekans
odometer
0
2500
5000
7500
10000
12500
15000
17500
0
50000
100000
150000
200000
250000
300000

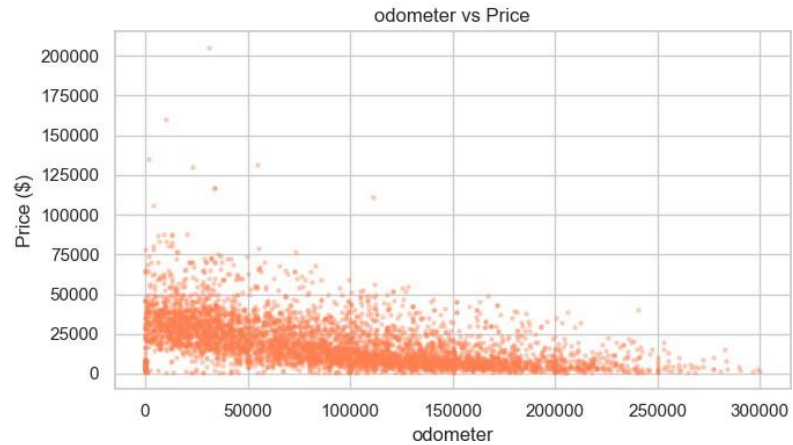
odometer vs Price
Price ($)
odometer
0
25000
50000
75000
100000
125000
150000
175000
200000
0
50000
100000
150000
200000
250000
300000

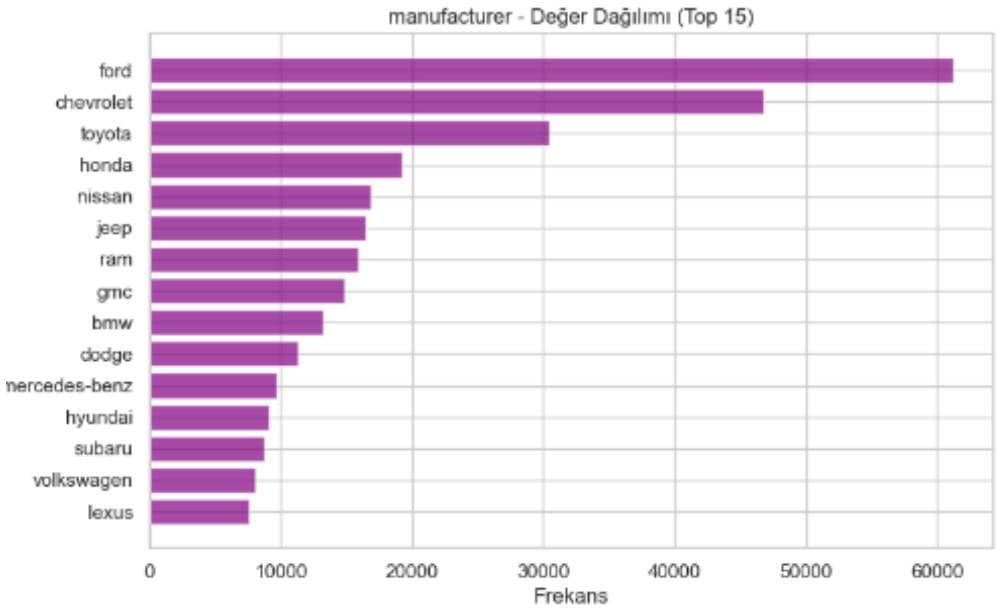
manufacturer - Değer Dağılımı (Top 15)
ford
chevrolet
toyota
honda
nissan
jeep
ram
gmc
bmw
dodge
mercedes-benz
hyundai
subaru
volkswagen
lexus
0
10000
20000
30000
40000
50000
60000
Frekans

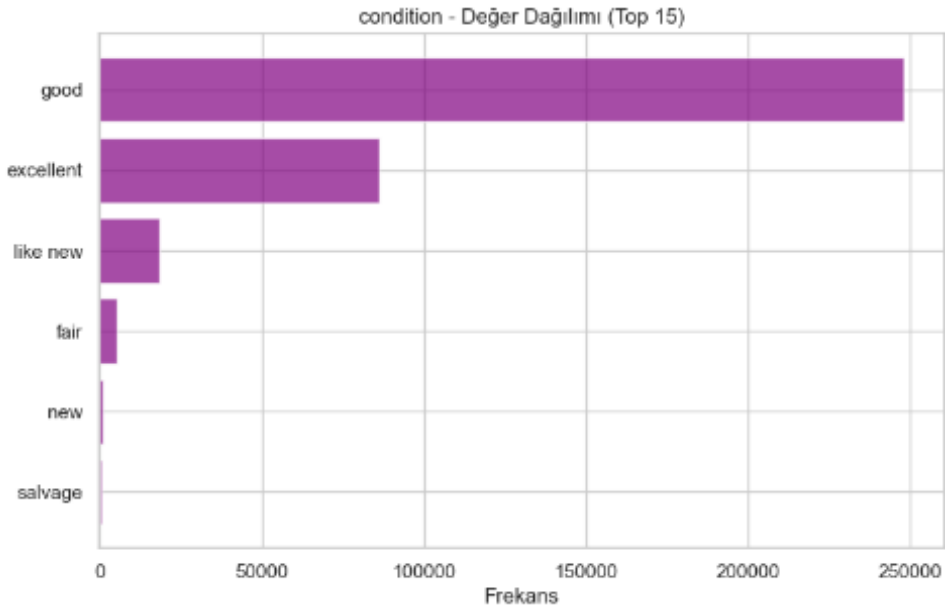
condition - Değer Dağılımı (Top 15)
good
excellent
like new
fair
new
salvage
0
50000
100000
150000
200000
250000
Frekans

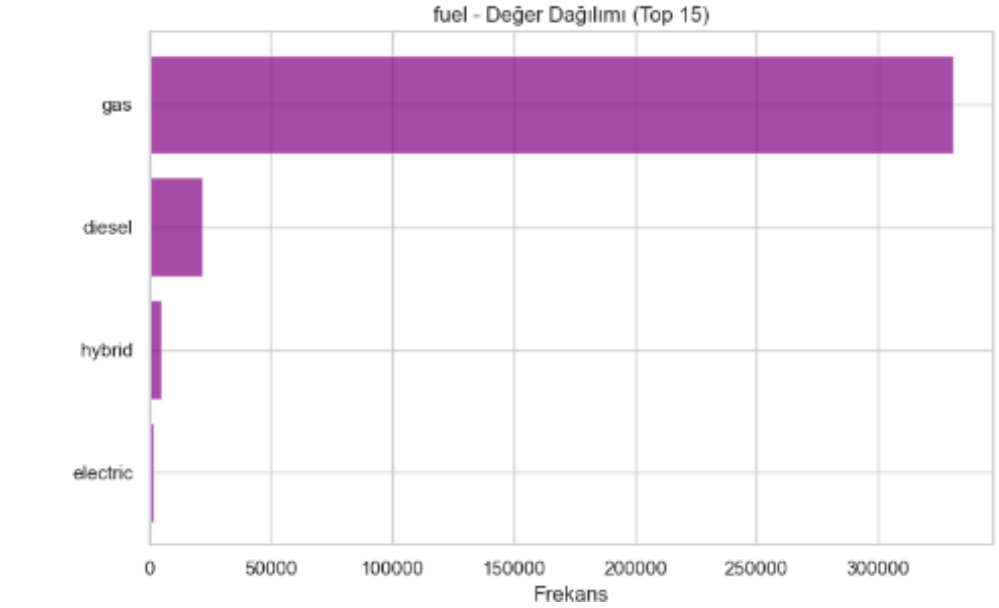
fuel - Değer Dağılımı (Top 15)
gas
diesel
hybrid
electric
0
50000
100000
150000
200000
250000
300000
Frekans

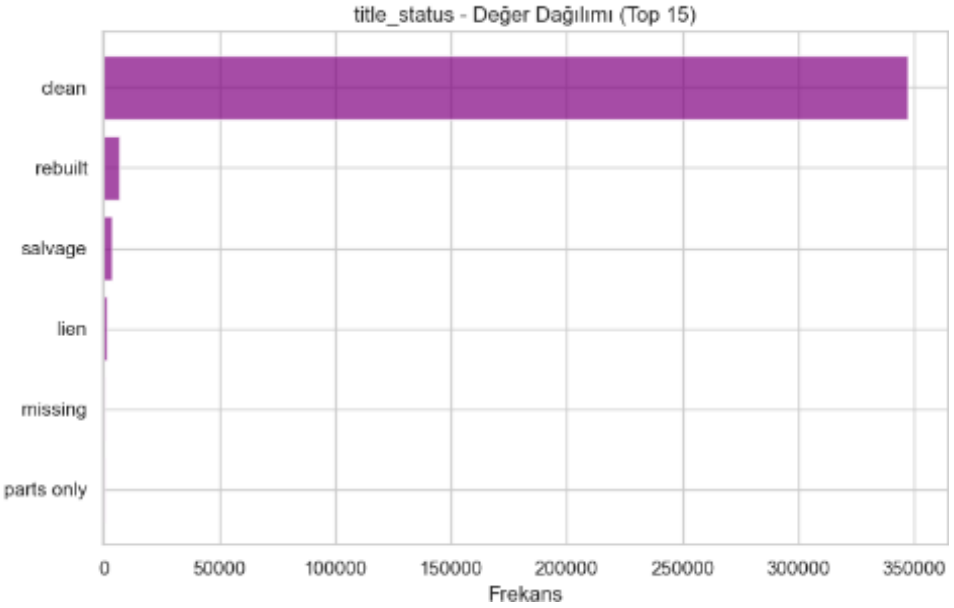
title_status - Değer Dağılımı (Top 15)
clean
rebuilt
salvage
lien
missing
parts only
0
50000
100000
150000
200000
250000
300000
350000
Frekans

Her bir ekip üyesi farklı feature engineering modelleri + sabit bir baseline model kullanarak farklı feature engineering tekniklerinin direkt olarak R2 , RMSE , MAE metriklerine etkisini test etmiştir. Kullanılan bazı feature engineering teknikleri:

```python
# 1) Arac yasi
df['car_age'] = 2025 - df['year']
print('car_age eklendi')

# 2) Yillik km
df['mil_per_year'] = df['odometer'] / df['car_age'].replace(0, 1)
print('mil_per_year eklendi')

# 3) Condition duzeltme (km bazli)
def correct_condition(row):
    odometer = row['odometer']
    if odometer <= 10000: return 'new'
    elif odometer <= 50000: return 'like new'
    elif odometer <= 100000: return 'excellent'
    elif odometer <= 150000: return 'good'
    else: return 'fair'

df['condition'] = df.apply(correct_condition, axis=1)
print('condition km bazli duzeltildi')
```

```python
def categorize_age(age):
    if age <= 2:
        return 'brand_new'
    elif age <= 5:
        return 'new'
    elif age <= 10:
        return 'mid_age'
    elif age <= 15:
        return 'old'
    else:
        return 'very_old'

df['age_category'] = df['car_age'].apply(categorize_age)
```

```python
def categorize_engine(cylinders):
    if cylinders <= 4:
        return 'small_engine'
    elif cylinders <= 6:
        return 'medium_engine'
    else:
        return 'large_engine'

df['engine_category'] = df['cylinders'].apply(categorize_engine)
```

```
=== TYPE DOLDURMA (MODEL BİLGİSİ İLE) ===

Başlangıç type null: 86295
1) Model isminden type çıkarılıyor...
   Sonrası null: 49988
2) Manufacturer bazlı mode...
   Sonrası null: 0
3) Kalan null'lar 'unknown' yapılıyor...
   Final null: 0

Type doldurma tamamlandı!

Type dağılımı:
type
sedan          117634
SUV             90340
pickup          74027
truck           33492
other           21246
coupe           20649
hatchback       17236
van             10720
wagon           10532
convertible      7152
mini-van         4682
offroad           570
bus               314
Name: count, dtype: int64
```

```
Toplam canonical model sayısı: 665
Toplam model varyant sayısı: 1050

================================================================================
MODEL NORMALİZASYON İŞLEMİ
================================================================================

Ham model NaN sayısı: 4,452
Normalize edilmiş model sayısı: 364,044

Sözlükte olmayan model sayısı: 202,516
Bu modeller 'unknown' olarak işaretlenecek (silinmeyecek)

Final dataframe boyutu: 368,498 satır (veri kaybı yok!)
Model kolonu hazır: 364,044 normalize edilmiş model
  - Bilinen modeller: 165,982
  - Unknown modeller: 202,516

================================================================================
MODEL NORMALİZASYON TAMAMLANDI
================================================================================

================================================================================
UNKNOWN MODEL DEĞERLERİNİ DOLDURMA (Manufacturer'a göre)
================================================================================

Doldurulacak unknown model sayısı: 202,516

Manufacturer bazında en popüler modeller bulundu: 40 manufacturer

Doldurma sonuçları:
  - Doldurulan model sayısı: 202,100
  - Kalan unknown model sayısı: 416
  - Doldurma oranı: 99.8%
  - Kalan 416 unknown değer 'other' olarak işaretlendi

================================================================================
UNKNOWN MODEL DOLDURMA TAMAMLANDI
================================================================================
```

Train Test Split Oranı : %80 Train %20 Test

Kullanılan Performans metrikleri : R2 , MAE , RMSE

Proje boyunca yapılan deneyler sonucunda, hem eğitim sürecinde GPU desteği sayesinde hızlı bir şekilde eğitilebilmesi hem de test verisi üzerinde en iyi performans metriklerini sağlaması nedeniyle **XGBoost** modeli en başarılı model olarak belirlenmiştir.

Model geliştirme sürecinde , hiperparametre optimizasyonu için en güçlü rakibi GridSearchCV den çok daha hızlı olmasına rağmen yakın verimlilikte sonuç vermesi sebebiyle çoğunlukla RandomizedSearchCV kullanıldı. RandomizedSearchCV ile optimizasyon sürecinde ağaç sayısı, maksimum derinlik, öğrenme oranı ve örnekleme oranı gibi temel hiperparametreler ayarlanmıştır.

Modelin eğitilmesinde kullanılan feature seti; aracın üretim yılı, kilometre bilgisi, motor özellikleri, yakıt türü, şanzıman tipi, araç tipi, çekiş türü, üretici bilgisi ve coğrafi konum gibi hem sayısal hem de kategorik özelliklerden oluşmaktadır. Kategorik değişkenler uygun encoding yöntemleri ile dönüştürülmüş, sayısal değişkenler ise ölçeklendirilerek modele dahil edilmiştir.

Buğra	Random Forest Regressor	RandomizedSearchCV (n_iter=12, cv=3)	n_estimators=400, max_depth=20, min_samples_split=5, min_samples_leaf=2, max_features="sqrt"	RMSE, MAE, R²
Buğra	PyTorch Neural Network (MLP)	Manual Tuning	learning_rate=0.001, batch_size=32, epochs=50	RMSE, Loss, R²
Emirhan	XGBoost Regressor	RandomizedSearchCV (n_iter=30, cv=3)	n_estimators=1000, max_depth=8, learning_rate=0.05, subsample=0.8	RMSE, MAE, R²
Emirhan	LightGBM Regressor	RandomizedSearchCV (n_iter=30, cv=3)	n_estimators=500, max_depth=10, learning_rate=0.1, num_leaves=31	RMSE, MAE, R²
Utku	Bagging Ensemble (KNN)	RandomizedSearchCV (n_iter=10, cv=3)	n_estimators=200, max_samples=1.0, learning_rate=0.1	RMSE, MAE, R²
Utku	CatBoost	Randomized Search	n_estimators=800, max_depth=8, learning_rate=0.05, loss_function="RMSE"	RMSE, MAE, R²
Alper	HistGradientBoostingRegressor	Manual Tuning (iterative parameter refinement)	max_depth=15, learning_rate=0.03, max_iter=800	RMSE, MAE, R²
Alper	Stacking Regressor	Grid Search (meta-model & base model selection)	base_models=[RF, LGBM, XGB], final_estimator=LinearRegression	RMSE, MAE, R²

XGBoost : 0.8869

Random Forest : 0.8831

LightGBM : 0.8698

Bagging KNN : 0.8380

Stacking Regressor : 0.8202

CatBoost : 0.8178

HistGradientBoosting : 0.7299

PyTorch ResNet MLP : 0.7152

Random Forest : 3,950.88

XGBoost : 3,992.31

LightGBM : 4,389.76

Bagging KNN : 5,153.38

Stacking Regressor : 5,375.21

CatBoost : 5,473.67

HistGradientBoosting : 7,602.93

PyTorch ResNet MLP : 7,956.78

Bagging KNN : 2,033.50

Random Forest : 2,220.24

XGBoost : 2,393.11

Stacking Regressor : 2,426.28

LightGBM : 2,745.36

CatBoost : 2,660.70

HistGradientBoosting : 4,152.12

PyTorch ResNet MLP : 4,423.55

Bu projede, ikinci el araç fiyatlarını tahmin etmeye yönelik bir regresyon problemi ele alınmış ve farklı makine öğrenmesi modelleri test verisi üzerinde R^2, RMSE ve MAE metrikleri kullanılarak karşılaştırılmıştır. Elde edilen sonuçlara göre, boosting tabanlı XGBoost modeli, test verisi üzerinde en yüksek R^2 değerine ulaşarak fiyat değişkenindeki varyansın büyük bir kısmını açıklamayı başarmış ve genel olarak en verimli modeli oluşturmuştur.

Buna karşılık Random Forest modeli, RMSE ve MAE metriklerinde en düşük hata değerlerini vererek tahmin hatalarının minimize edilmesi açısından öne çıkmıştır. Bu durum, farklı modellerin farklı performans metrikleri açısından avantaj sağlayabildiğini göstermektedir.Buna karşılık Random Forest modeli, RMSE ve MAE metriklerinde en düşük hata değerlerini vererek tahmin hatalarının minimize edilmesi açısından öne çıkmıştır. Bu durum, farklı modellerin farklı performans metrikleri açısından avantaj sağlayabildiğini göstermektedir.

Hiperparametre optimizasyonu aşamasında, hesaplama maliyeti ve verimlilik dengesi gözetilerek RandomizedSearchCV yöntemi tercih edilmiştir. Ayrıca hedef değişkene uygulanan log dönüşümü, modelin daha stabil öğrenmesine katkı sağlamıştır. Genel değerlendirme sonucunda, proje kapsamında belirlenen performans kriterlerinin büyük ölçüde karşılandığı ve XGBoost modelinin en başarılı model olduğu sonucuna varılmıştır.